Estimasi Tingkat Kekeruhan Air Berdasarkan Pemrosesan Citra Digital untuk Mendukung SDG 6

Abyan Raga Kusuma[1], Iqbal Khafidz Abrori[2] and NIM 234311001[1], 234311015[2]
Program Studi Teknologi rekayasa perangkat lunak
Fakultas teknik
Politeknik negeri madiun, Jl. Ring Road Barat, Kel. Winongo, Kec. Manguharjo
[1]234311001@student.pnm.ac.id, [2]234311015@student.pnm.ac.id

Abstract*— Akses terhadap air bersih merupakan target utama dari Sustainable Development Goal (SDG) 6. Penelitian ini bertujuan untuk mengestimasi tingkat kekeruhan air menggunakan pemrosesan citra digital sebagai alternatif pemantauan yang murah dan efisien. Penelitian ini menggunakan dataset UIDLEIA dari Mendeley Data yang terdiri dari 135 citra bawah air dengan nilai Mean Acceptance Value (MAV) sebagai label target. Metode ekstraksi fitur hybrid yang menggabungkan fitur warna (RGB dan HSV) serta fitur tekstur (GLCM: Contrast dan Homogeneity) diimplementasikan dalam riset ini. Dua model machine learning, yaitu Random Forest dan Artificial Neural Network (ANN), dibandingkan untuk mengevaluasi performa prediksinya. Hasil eksperimen menunjukkan bahwa model ANN mengungguli Random Forest dengan nilai R^2 Score sebesar 0,9008 dan Mean Absolute Error (MAE) yang lebih rendah. Lebih lanjut, studi ablasi fitur mengungkapkan bahwa tekstur GLCM merupakan deskriptor yang paling kritis, di mana penghapusannya menyebabkan penurunan akurasi yang signifikan. Sebaliknya, penghapusan fitur RGB pada model Random Forest justru meningkatkan performa, mengidentifikasi RGB sebagai noise akibat variasi pencahayaan bawah air. Penelitian ini mengonfirmasi bahwa integrasi fitur hybrid dan jaringan saraf tiruan memberikan solusi presisi tinggi untuk penilaian kualitas air secara digital.

***Kata Kunci*— ANN, GLCM, Kualitas Air, MAV, Random Forest, SDG 6.**

I. PENDAHULUAN

Akses terhadap air bersih dan sanitasi yang layak merupakan salah satu pilar utama dalam Sustainable Development Goals (SDG) ke-6. Namun, degradasi kualitas sumber air menjadi permasalahan global yang memerlukan metode deteksi cepat, murah, dan mudah diimplementasikan. Pemantauan kualitas air secara konvensional umumnya mengandalkan analisis laboratorium yang membutuhkan biaya tinggi serta waktu yang relatif lama [1]. Oleh karena itu, diperlukan inovasi teknologi yang mampu melakukan estimasi kualitas air secara praktis dan non-kontak.

Perkembangan teknologi Pengolahan Citra Digital (PCD) dan Machine Learning menawarkan solusi menjanjikan untuk mengatasi kendala tersebut. Dengan memanfaatkan fitur warna digital, karakteristik air dapat diidentifikasi secara objektif. Penggunaan fitur warna seperti RGB (Red, Green, Blue) dan HSV (Hue, Saturation, Value) telah terbukti efektif sebagai deskriptor dalam menentukan klasifikasi kualitas air [1]. Selain fitur warna, informasi tekstur dari citra juga memegang peranan krusial, terutama pada lingkungan bawah air yang memiliki tantangan visual kompleks. Integrasi fitur tekstur menggunakan Gray Level Co-occurrence Matrix (GLCM) bersama dengan ruang warna hybrid diketahui dapat meningkatkan performa analisis citra secara signifikan [2].

Dalam implementasinya, pemilihan algoritma Machine Learning yang tepat sangat menentukan akurasi sistem. Penelitian terdahulu telah mengeksplorasi penggunaan Random Forest sebagai model yang tangguh untuk klasifikasi dan prediksi kualitas air [3]. Di sisi lain, penggunaan jaringan saraf tiruan atau Artificial Neural Network (ANN) juga menunjukkan keunggulan dalam memprediksi parameter fisik dan kimia air karena kemampuannya dalam memetakan hubungan data yang non-linear [4].

Penelitian ini bertujuan untuk melakukan estimasi tingkat kekeruhan air dengan membandingkan performa algoritma Random Forest dan ANN menggunakan dataset UIDLEIA dari Mendeley Data. Fokus utama penelitian ini adalah mengevaluasi penggunaan fitur hybrid (warna dan tekstur) serta melakukan studi ablasi untuk membuktikan pengaruh masing-masing fitur terhadap akurasi model. Hasil dari penelitian ini diharapkan dapat menjadi referensi dalam pengembangan sistem monitoring air yang efisien guna mendukung tercapainya target SDG 6.

II. TINJAUAN PUSTAKA

A. Ruang Warna HSV (Hue, Saturation, Value)

Pengolahan citra digital telah berkembang pesat sebagai instrumen pemantauan kualitas lingkungan yang efisien dan objektif. Dalam estimasi kualitas air, salah satu pendekatan yang paling stabil adalah penggunaan ruang warna HSV. Berbeda dengan model RGB yang sensitif terhadap fluktuasi intensitas cahaya, model HSV memisahkan komponen warna dari tingkat kecerahannya (Value). Penggunaan ruang warna ini terbukti krusial untuk memitigasi gangguan pencahayaan pada citra bawah air dibandingkan model RGB konvensional [1].

Secara matematis, komponen Value (V) didefinisikan

sebagai:

$$V = \max(R, G, B)$$

dengan:
V : Indikator kecerahan warna dalam model HSV.
max(R, G, B) : Mengambil nilai tertinggi dari kanal Merah, Hijau, atau Biru.

B. Gray Level Co-occurrence Matrix (GLCM)

Selain aspek warna, fitur tekstur menjadi parameter kritis dalam mendeskripsikan karakteristik kekeruhan. GLCM digunakan untuk menganalisis hubungan spasial antar piksel guna mengukur kekasaran objek. Integrasi fitur hybrid antara warna dan tekstur mampu menangkap detail partikel tersuspensi yang tidak terdeteksi oleh sensor warna semata [2]. Parameter utama yang digunakan meliputi:

1. Contrast (C): Mengukur variasi intensitas lokal.

$$\sum_{i,j} |i - j|^2 p(i,j)$$

dengan:
|i - j|: Selisih nilai piksel (jarak).
^{2} : Pengali bobot (memperbesar efek kontras).
(i, j) : Probabilitas pasangan piksel.

2. Homogeneity (H): Mengukur keseragaman distribusi elemen dalam matriks.

$$\sum_{i,j} \frac{p(i,j)}{1 + |i - j|}$$

dengan:
p(i, j): Probabilitas pasangan piksel.
1: Penjaga agar tidak terjadi pembagian nol.
|i - j|: Pembagi (semakin besar selisih, nilai akhir semakin kecil).

C. Artificial Neural Network (ANN)

Arsitektur ANN menawarkan fleksibilitas tinggi dalam memetakan hubungan non-linear antara fitur input dan target Mean Acceptance Value (MAV). ANN dapat mempelajari pola data kontinu melalui proses backpropagation [4]. Secara matematis, keluaran jaringan dirumuskan sebagai berikut:

1. Aktivasi Hidden Layer:

$$h_j = f\left(\sum_{i=1}^{n} w_{ij} x_i + b_j\right)$$

dengan:
xi: nilai input ke-i
wij: bobot antara input ke-i dan neuron hidden ke-j
bj: bias pada neuron hidden
f(·): fungsi aktivasi

2. Aktivasi Output Layer (Prediksi ŷ):

$$y = g\left(\sum_{j=1}^{m} v_j h_j + c\right)$$

dengan:
hj: keluaran neuron ke-j pada hidden layer
vj: bobot antara hidden neuron ke-j dan output \
c: bias pada output layer
g(·): fungsi aktivasi output (regresi biasanya menggunakan fungsi linear)

D. Random Forest Regression (RF)

Algoritma ensemble seperti Random Forest menjadi standar dalam menangani data regresi yang kompleks. Metode ini memiliki ketangguhan tinggi dalam memprediksi kualitas air dengan menggabungkan hasil dari banyak decision trees untuk meminimalkan varian [3]:

$$y_{RF}(x) = \left(\frac{1}{T}\right)\sum_{t=1}^{T} h_t(x)$$

dengan:
T: jumlah pohon dalam hutan
ht(x): prediksi dari pohon ke-t

E. Metrik Evaluasi Performa

Untuk mengukur keakuratan model dalam mengestimasi nilai MAV, digunakan dua metrik utama:

1. Mean Absolute Error (MAE):

$$MAE = \frac{1}{n}\sum |\, y_i - \{y\}_i|$$

dengan:
1/n : Rata-rata (1 dibagi jumlah data n).
yi : Nilai aktual (data asli).
{y}i : Nilai prediksi (hasil hitungan model).

2. R-Squared (R2):

$$R2 = \big(corr(y,y)\big)2$$

dengan:
R2 : Koefisien determinasi (seberapa akurat model).
Corr : Korelasi antara nilai asli (*y*) dan nilai prediksi {*y*}.
^{2} : Nilai korelasi yang dikuadratkan.
Model terbaik dipilih berdasarkan nilai R2 terbesar dan RMSE/MAE terkecil.

III. METODOLOGI PENELITIAN

A. Alur Penelitian

Penelitian ini dilakukan secara sistematis melalui beberapa tahapan utama untuk memastikan model yang dihasilkan memiliki akurasi yang optimal. Tahapan dimulai dari akuisisi data dari sumber publik, diikuti dengan pemrosesan awal citra, ekstraksi fitur hybrid, hingga tahap pelatihan dan evaluasi model.

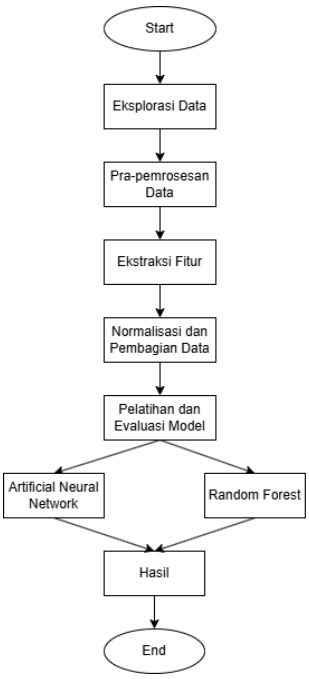

Fig. 1. Diagram alir penelitian

B. Eksplorasi Data

Data yang digunakan dalam penelitian ini adalah dataset publik UIDLEIA yang diperoleh melalui repositori Mendeley Data. Dataset ini terdiri dari 135 citra bawah air yang mencakup berbagai kondisi degradasi visual. Eksplorasi data menunjukkan bahwa setiap citra memiliki karakteristik warna dan tekstur yang berbeda-beda tergantung pada tingkat kekeruhan air. Label target yang digunakan adalah nilai Mean Acceptance Value (MAV) dengan rentang 0 hingga 100, di mana nilai tersebut merepresentasikan persepsi subjektif manusia terhadap kualitas citra air tersebut.

C. Pra-pemrosesan Data

Sebelum masuk ke tahap ekstraksi fitur, dilakukan tahap pra-pemrosesan untuk menyeragamkan input. Tahapan ini meliputi:

1. Resize Citra: Mengubah ukuran seluruh citra menjadi 128x128 piksel untuk mengurangi beban komputasi namun tetap mempertahankan informasi visual yang krusial.
2. Konversi Ruang Warna: Citra asli dalam format BGR/RGB dikonversi ke dalam ruang warna HSV (Hue, Saturation, Value) untuk mendapatkan informasi intensitas cahaya dan saturasi yang lebih stabil dibandingkan RGB [1].

D. Ekstraksi Fitur

Penelitian ini menerapkan metode Hybrid Feature Extraction yang menggabungkan dua domain utama:

3. Fitur Warna: Mengekstraksi nilai rata-rata (mean) dari kanal R, G, B serta kanal H, S, V. Total terdapat 6 fitur warna yang merepresentasikan karakteristik tonal air.
4. Fitur Tekstur (GLCM): Menggunakan metode Gray Level Co-occurrence Matrix (GLCM) untuk menangkap pola kekaburan akibat partikel tersuspensi. Parameter yang diekstraksi adalah Contrast (mengukur intensitas lokal) dan Homogeneity (mengukur kedekatan distribusi elemen dalam GLCM). Penggunaan fitur ini menyatakan bahwa GLCM sangat efektif untuk citra bawah air [2].

E. Normalisasi dan Pembagian Data

Mengingat fitur yang diekstraksi memiliki skala nilai yang berbeda (misalnya nilai warna 0-255 sementara GLCM memiliki skala yang berbeda), maka dilakukan Normalisasi menggunakan StandardScaler. Hal ini bertujuan untuk mengubah distribusi data sehingga memiliki rata-rata 0 dan standar deviasi 1, yang sangat penting bagi algoritma seperti ANN agar proses konvergensi lebih cepat. Data kemudian dibagi (Splitting) dengan rasio 80% untuk data latih (training) dan 20% untuk data uji (testing).

F. Pelatihan dan Evaluasi Model

Dua algoritma machine learning dibandingkan dalam penelitian ini:

1. Random Forest Regressor: Digunakan sebagai model berbasis ensemble tree untuk menangani data tabular hasil ekstraksi fitur.
2. Artificial Neural Network (ANN): Menggunakan arsitektur Multi-Layer Perceptron (MLP) untuk memetakan hubungan non-linear antara fitur hybrid dengan nilai MAV.

Evaluasi model dilakukan menggunakan metrik R-Squared (R^2 Score) untuk melihat sejauh mana model dapat menjelaskan varians data, serta Mean Absolute Error (MAE) untuk menghitung rata-rata kesalahan absolut antara nilai prediksi dan nilai aktual MAV. Selain itu, dilakukan Studi Ablasi untuk menganalisis kontribusi masing-masing grup fitur terhadap akurasi final.

IV. HASIL DAN PEMBAHASAN

A. Analisis Metrik Evaluasi Model Regresi

Penelitian ini mengevaluasi kinerja model menggunakan dua metrik utama: R-Squared (R^2) dan Mean Absolute Error (MAE). Hasil komparasi antara algoritma Random Forest (RF) dan Artificial Neural Network (ANN) disajikan pada Table I.

Tabel I. Perbandingan Performa Model Regresi

Algoritma	R^2 Score	MAE
Random Forest (RF)	0.8537	7.55
ANN (Multi-Layer Perceptron)	0.9008	6.36

Berdasarkan Table I, ANN menunjukkan dominansi performa dengan nilai R^2 mencapai 0.9008. Secara teoritis, keunggulan ANN terletak pada struktur hidden layers yang memungkinkan model melakukan pemetaan non-linear yang sangat kompleks antara fitur hybrid (warna dan tekstur) dengan target MAV. Sebaliknya, meskipun RF memiliki ketangguhan terhadap outlier, sifat algoritma ini yang berbasis ensemble dari decision trees terkadang

mengalami limitasi dalam menangkap variasi data kontinu yang sangat halus dibandingkan dengan fleksibilitas bobot pada jaringan saraf [3].

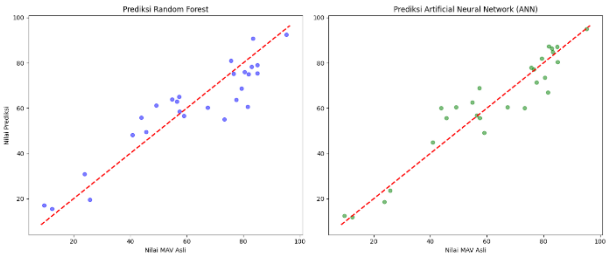

Fig. 2. Scatter plot kesesuaian nilai prediksi terhadap nilai MAV asli.

Visualisasi pada Fig. 2 memperkuat temuan kuantitatif dengan menunjukkan perbandingan distribusi titik prediksi terhadap garis ideal diagonal merah, di mana plot Artificial Neural Network (hijau) menunjukkan kerapatan titik yang sangat tinggi dan konsisten mengikuti garis di seluruh rentang nilai MAV. Hal ini membuktikan bahwa arsitektur jaringan saraf memiliki kemampuan generalisasi yang unggul dalam menangkap hubungan non-linear yang kompleks antara fitur hybrid (tekstur dan warna) dengan tingkat kekeruhan air yang sebenarnya.

Sebaliknya, plot pada Random Forest (biru) memperlihatkan dispersi atau penyebaran titik yang lebih lebar menjauhi garis ideal, yang mencerminkan deviasi prediksi atau nilai MAE yang lebih tinggi (7,55). Analisis visual ini mengonfirmasi bahwa meskipun model ensemble cukup tangguh, ia memiliki keterbatasan dalam merespons variasi data kontinu yang halus pada citra bawah air, sehingga penggunaan ANN tetap menjadi pilihan yang lebih stabil dan presisi dalam memitigasi noise untuk sistem estimasi kekeruhan ini.

B. Hasil Studi Ablasi Fitur

Studi ablasi dilakukan untuk membedah kontribusi masing-masing domain fitur terhadap kemampuan prediksi model. Hasil eksperimen pada model Artificial Neural Network (ANN) dan Random Forest (RF) ditunjukkan pada Table II dan Table III.

Tabel II. Hasil Studi Ablasi Fitur pada Model Artifial Neural Network

Skenario Fitur	R^2 Score	Perubahan Performa
Fitur Hybrid (Lengkap)	0.9008	-
Tanpa Fitur Warna HSV	0.8812	-2.17%
Tanpa Fitur Warna RGB	0.8983	-0.27%
Tanpa Fitur Tekstur GLCM	0.6365	-29.34%

Tabel III. Hasil Studi Ablasi Fitur pada Model Random Forest

Skenario Fitur	R^2 Score	Perubahan Performa
Fitur Hybrid (Lengkap)	0.8537	-
Tanpa Fitur Warna HSV	0.8421	-1.36%
Tanpa Fitur Warna RGB	0.8644	+1.25%
Tanpa Fitur Tekstur GLCM	0.5820	-31.83%

Data pada kedua tabel di atas menunjukkan bahwa fitur tekstur GLCM adalah variabel paling vital dalam sistem ini. Tanpa GLCM, performa model ANN merosot tajam sebesar 29,34%, sementara pada model RF terjadi penurunan lebih drastis sebesar 31,83%. Secara ilmiah, hal ini membuktikan bahwa kekeruhan air dalam dataset UIDLEIA lebih banyak direpresentasikan oleh pola spasial dan kekasaran butiran objek (tekstur) daripada sekadar informasi tonal warna. Parameter Contrast pada GLCM secara efektif menangkap perbedaan intensitas piksel bertetangga yang muncul akibat partikel tersuspensi, yang merupakan indikator fisik utama kekeruhan air.

C. Efektivitas Ruang Warna HSV terhadap RGB

Berdasarkan perbandingan Table II dan Table III, terlihat perbedaan karakteristik yang krusial pada fitur warna RGB. Pada model ANN, penghapusan fitur RGB menyebabkan sedikit penurunan performa (0,27%), namun pada model RF, penghapusan fitur RGB justru meningkatkan akurasi menjadi 0,8644 (naik 1,25%). Hal ini mengonfirmasi bahwa kanal RGB mengandung noise yang tinggi akibat fenomena light attenuation (penyerapan cahaya) di bawah air. Cahaya merah (R) adalah yang pertama kali diserap oleh air, sehingga nilai piksel RGB cenderung tidak konsisten.

Sebaliknya, ruang warna HSV terbukti lebih representatif. Penghapusan HSV secara konsisten menurunkan performa pada kedua model (ANN -2,17% dan RF -1,36%). Secara teoritis, kanal Hue dan Saturation mampu merepresentasikan warna air tanpa terpengaruh oleh intensitas cahaya (Value), memungkinkan model mengenali kondisi air dengan lebih presisi meski terjadi variasi pencahayaan.

D. Korelasi Hasil dengan Target SDG 6

Secara teoritis, sistem estimasi ini memenuhi prinsip efisiensi dan aksesibilitas yang ditekankan dalam SDG 6. Dengan tingkat error (MAE) yang rendah (6,36), sistem ini mampu memberikan penilaian kualitas air yang mendekati persepsi manusia (MAV) secara otomatis. Hal ini membuktikan bahwa integrasi hybrid feature extraction dan deep learning sederhana dapat memitigasi ketergantungan pada alat sensor fisik yang mahal dan sulit dirawat di area terpencil.

V. KESIMPULAN

Berdasarkan hasil eksperimen dan analisis yang telah dilakukan, dapat disimpulkan bahwa penggunaan pemrosesan citra digital dengan pendekatan machine learning mampu memberikan estimasi kekeruhan air yang akurat untuk mendukung target SDG 6. Model Artificial Neural Network (ANN) terbukti lebih unggul dalam memetakan karakteristik non-linear pada citra bawah air dibandingkan model Random Forest, dengan pencapaian R^2 Score sebesar 0,9008 dan tingkat kesalahan (MAE)

terendah sebesar 6,36.

Penelitian ini secara ilmiah membuktikan bahwa fitur tekstur (GLCM) adalah deskriptor paling kritis, di mana penghapusannya menyebabkan penurunan akurasi yang signifikan hingga melampaui 29% pada kedua model. Hal ini menunjukkan bahwa informasi spasial pada citra air jauh lebih representatif dalam mendeskripsikan kekeruhan dibandingkan fitur warna semata.

Selain itu, ditemukan fenomena penting di mana penggunaan ruang warna HSV terbukti lebih tangguh terhadap variasi pencahayaan (noise) dibandingkan RGB. Secara spesifik, pada model Random Forest, penghapusan fitur RGB justru meningkatkan performa menjadi 0,8644, yang mengonfirmasi bahwa kanal RGB dapat bertindak sebagai noise pada citra bawah air akibat penyerapan cahaya yang tidak konsisten. Sistem yang dikembangkan ini diharapkan dapat menjadi alternatif solusi pemantauan kualitas air yang murah, cepat, dan efisien untuk mendukung pengelolaan air bersih berkelanjutan.

REFERENSI

[1] M. I. M. Nur Jamal, "IMPLEMENTASI MACHINE LEARNING BERBASIS FITUR WARNA RGB DAN HSV UNTUK KLASIFIKASI KUALITAS AIR," *JITET*, vol. 14, no. 1, Jan 2026, doi: 10.23960/jitet.v14i1.8667.

[2] N. N. Apaydın, G. Karaduman, dan O. Yaman, "Hybrid Color Space and GLCM Feature Extraction Based Classification Method for Underwater Image Analysis," *Düzce Üniversitesi Bilim ve Teknoloji Dergisi*, vol. 13, no. 4, hlm. 1676–1694, Okt 2025, doi: 10.29130/dubited.1651026.

[3] N. Maulidah, M. Maulidah, R. Supriyadi, H. Nalatissifa, S. Diantika, dan A. Fauzi, "PREDIKSI KUALITAS AIR MENGGUNAKAN METODE RANDOM FOREST, DECISION TREE, DAN GRADIENT BOOSTING," *JKI*, vol. 12, no. 1, hlm. 1–6, Jul 2024, doi: 10.31294/jki.v12i1.16004.

[4] A. M. Ilyas, "PREDIKSI KUALITAS AIR DANAU LAGUNA DI TERNATE MENGGUNAKAN ARTIFICIAL NEURAL NETWORK," *Fs*, vol. 15, no. 2, Nov 2025, doi: 10.54757/fs.v15i2.821.

PERNYATAAN

Dengan ini saya menyatakan bahwa makalah yang saya tulis ini adalah tulisan saya sendiri, bukan saduran, atau terjemahan dari makalah orang lain, dan bukan plagiasi.

Madiun, 20 April 2026

ttd

Nama dan NIM